

Tarea de investigación

Procesamiento distribuido: teoría, tecnologías actuales y evolución

Objetivo de aprendizaje

- Comprender por qué el procesamiento distribuido surge cuando una sola computadora ya no puede almacenar, procesar o responder a tiempo ante grandes volúmenes de datos.
- Relacionar conceptos teóricos como nodos, particiones, clústeres, tolerancia a fallos, eventos y orquestación con tecnologías usadas actualmente en la industria.
- Explicar la descendencia tecnológica: de dónde viene la tecnología, qué problema heredó y hacia dónde evolucionó.
- Diseñar una explicación visual que permita enseñar el tema a otros compañeros sin depender de mucho texto.

Organización de la clase

Duración	1 hora de trabajo en clase
Modalidad	Grupos de 4 a 5 estudiantes
Producto final	Una lámina visual, infografía, mapa conceptual, línea del tiempo o diagrama de arquitectura
Herramientas sugeridas	Canva, Miro, FigJam, Genially, PowerPoint, Google Slides, Lucidchart o diagrams.net
Regla clave	El diseño visual se termina en clase. Debe quedar listo para explicar el tema de manera sencilla y creativa.

Instrucciones para los estudiantes

1. El grupo recibirá uno de los cinco temas asignados por el docente.
2. Investiguen la teoría esencial del tema, evitando copiar párrafos completos. Deben comprenderlo para explicarlo con sus propias palabras.
3. Identifiquen la tecnología actual, sus componentes principales y su relación con procesamiento distribuido.
4. Incluyan la descendencia tecnológica: qué existía antes, qué problema intentó resolver y cómo evolucionó hacia soluciones modernas.
5. Construyan un diseño visual terminado en clase. Puede ser una infografía, línea del tiempo, mapa conceptual o arquitectura con flujo de datos.
6. El diseño debe permitir explicar el tema fácilmente. Debe tener más elementos visuales que texto.
7. Incluyan al menos dos fuentes consultadas dentro del diseño o al pie de la lámina.
8. Cada grupo debe estar preparado para explicar su visual en 2 a 5 minutos máximo.

Importante

No se solicita un reporte largo. La evidencia principal es el diseño visual terminado en clase. El objetivo es que el grupo pueda explicar el tema de forma clara, técnica y creativa.

Preguntas guía obligatorias

1. ¿Qué problema de procesamiento distribuido resuelve esta tecnología o concepto?
2. ¿Qué pasaría si intentáramos resolver ese problema en una sola computadora?
3. ¿Cómo se divide el trabajo o los datos entre varios nodos, procesos o servicios?
4. ¿Cuáles son sus componentes principales? Ejemplo: nodos, particiones, workers, brokers, topics, executors, pods, scheduler o clúster.
5. ¿Cuál es su tecnología antecesora o el enfoque que existía antes?
6. ¿Cuál es su descendencia o evolución tecnológica actual?
7. ¿Qué tecnologías modernas la usan o la complementan?
8. ¿En qué caso real de industria se aplicaría? Banco, universidad, salud, IoT, retail, meteorología, transporte o redes sociales.
9. ¿Qué limitación, riesgo o reto técnico tiene?
10. ¿Cómo puede representarse visualmente para que otra persona lo entienda rápido?

Formato mínimo del diseño visual

- Título del tema y nombres de los integrantes.
- Una explicación visual central: flujo, arquitectura, línea del tiempo, comparación o mapa conceptual.
- Conceptos técnicos clave definidos en frases cortas.
- Evolución o descendencia tecnológica representada visualmente.
- Un caso real o escenario aplicado.
- Dos fuentes consultadas.

Ideas de diseño visual permitidas

Formato visual	Cuándo usarlo	Ejemplo aplicado
Línea del tiempo	Cuando el tema tiene evolución histórica o descendencia tecnológica.	MapReduce → Spark → Spark en cloud
Diagrama de arquitectura	Cuando se quiere mostrar componentes y flujo de datos.	Fuentes → Kafka → Flink → Dashboard
Mapa conceptual	Cuando el tema tiene muchos conceptos relacionados.	Kubernetes: pods, nodos, deployments, services
Infografía comparativa	Cuando se desea comparar antes/después o ventajas/desventajas.	Hadoop on-premise vs Hadoop en la nube

Temas asignables

Tema 1: De MapReduce a Apache Spark

Enfoque de investigación	Investigar cómo MapReduce permitió procesar datos masivos dividiendo un trabajo en varias tareas y cómo Apache Spark evolucionó este modelo con procesamiento más flexible y rápido.
Componentes que deben aparecer	Map, Reduce, HDFS, YARN, driver, executors, particiones, RDD, DataFrame y Spark SQL.
Descendencia / evolución tecnológica	Google MapReduce → Hadoop MapReduce → Spark RDD → Spark DataFrame / Spark SQL → Spark Structured Streaming y Spark en la nube.
Caso de uso sugerido	Procesamiento nocturno de millones de registros académicos para calcular indicadores de riesgo estudiantil.
Idea visual recomendada	Línea del tiempo más un diagrama: archivo grande → particiones → nodos → resultado final.

Tema 2: Kafka y el procesamiento basado en eventos

Enfoque de investigación	Explicar cómo los sistemas modernos no solo procesan archivos acumulados, sino eventos que ocurren constantemente: pagos, clics, sensores, logs o acciones de usuarios.
Componentes que deben aparecer	Productores, brokers, topics, particiones, consumidores, offsets y eventos.
Descendencia / evolución tecnológica	Colas de mensajes → modelo publish/subscribe → Apache Kafka → Kafka Streams, arquitecturas event-driven y servicios cloud de streaming.
Caso de uso sugerido	Una plataforma bancaria que publica cada transacción como evento para detectar fraude o alimentar dashboards en tiempo real.
Idea visual recomendada	Diagrama de flujo: productores → Kafka topics/particiones → consumidores → alertas o dashboards.

Tema 3: Apache Flink y el procesamiento en tiempo real

Enfoque de investigación	Investigar por qué algunos casos requieren procesar datos mientras llegan, no horas después. Flink se enfoca en streaming con estado, ventanas de tiempo y tolerancia a fallos.
Componentes que deben aparecer	Streams, operadores, estado, ventanas, event time, checkpoints, fuentes y sinks.
Descendencia / evolución tecnológica	Procesamiento batch → micro-batch → motores de streaming → Flink DataStream API / Flink SQL / procesamiento con estado.
Caso de uso sugerido	Sensores IoT que envían temperatura cada segundo y generan una alerta cuando se detecta un patrón peligroso.
Idea visual recomendada	Flujo visual de eventos: sensor → stream → ventana de tiempo → regla de alerta → acción inmediata.

Tema 4: Hadoop y Spark en la nube

Enfoque de investigación	Investigar cómo el procesamiento distribuido pasó de clústeres físicos administrados por la empresa a servicios cloud administrados que pueden crearse, escalarse y apagarse bajo demanda.
Componentes que deben aparecer	Data Lake cloud, almacenamiento separado del cómputo, clúster administrado, nodos, jobs, Spark, Hadoop, Hive y notebooks.
Descendencia / evolución tecnológica	Hadoop on-premise → clústeres administrados como Amazon EMR, Azure HDInsight o Google Dataproc/Managed Spark → serverless Spark y lakehouse.
Caso de uso sugerido	Una universidad guarda datos crudos en un Data Lake cloud y levanta un clúster temporal para procesar 10 años de matrícula, pagos, asistencia y logs.
Idea visual recomendada	Arquitectura cloud: fuentes → Data Lake RAW/SILVER/GOLD → clúster Hadoop/Spark → dashboard o modelo predictivo.

Tema 5: Contenedores y Orquestación (Kubernetes)

Enfoque de investigación	Explicar cómo los contenedores permiten empaquetar aplicaciones de forma reproducible y cómo Kubernetes coordina muchos contenedores en un clúster.
Componentes que deben aparecer	Imagen, contenedor, pod, nodo worker, control plane, deployment, service, scheduler, escalamiento y self-healing.
Descendencia / evolución tecnológica	Servidores físicos → máquinas virtuales → contenedores Docker → Kubernetes → servicios administrados como EKS, AKS y GKE.
Caso de uso sugerido	Una API de captura de datos se ejecuta en varias réplicas; si una falla, Kubernetes crea otra y mantiene el servicio disponible.
Idea visual recomendada	Diagrama: imagen de aplicación → pods → nodos → clúster → escalamiento automático / recuperación ante fallos.

Criterios de evaluación

Criterio	Descripción	Valor
Claridad conceptual	Explica la teoría del tema con sus propias palabras y sin depender de texto copiado.	50%
Relación con procesamiento distribuido	Muestra cómo se distribuyen datos, trabajo, eventos o contenedores entre varios nodos o servicios.	25%
Descendencia tecnológica	Explica claramente de dónde viene la tecnología y hacia qué soluciones modernas evolucionó.	15%
Diseño visual y creatividad	El recurso visual es claro, ordenado, creativo y fácil de explicar.	10%

Fuentes sugeridas para iniciar la investigación

Los estudiantes pueden iniciar con documentación oficial y luego buscar ejemplos reales de industria. Fuentes recomendadas:

- [Apache Spark Documentation](#)
- [Apache Kafka Documentation](#)
- [Apache Flink Documentation](#)
- [Amazon EMR Documentation](#)
- [Azure HDInsight Documentation](#)
- [Google Cloud Managed Service for Apache Spark / Dataproc](#)
- [Kubernetes Documentation](#)

Entrega esperada

- Archivo o enlace del diseño visual terminado en clase.
- Captura de pantalla del diseño si la herramienta usada es en línea.
- Nombres de los integrantes visibles en el diseño.
- Fuentes consultadas dentro del diseño o en una sección pequeña al final.
- Preparación para una explicación breve, clara y técnica.